Projet de Classification Supervisée - Prédiction du Risque de Défaut de Crédit

Mohamed FOFANA, Abdou FALL

13 April 2026

Contents

1 Introduction et présentation du jeu de données **1**
1.1 Présentation générale . . . 1
1.2 Vérification des âges aberrants . . . 4
1.3 Valeurs manquantes . . . 4
1.4 Distribution de la variable cible . . . 4
1.5 Analyse univariée . . . 5
1.6 Analyse multivariée . . . 10

2 Prétraitement des données **14**
2.1 Feature engineering . . . 14

3 Classifieur 1 : Naïve Bayes **16**
3.1 Principe et justification . . . 16
3.2 Plan d'analyse . . . 16
3.3 Implémentation et choix de l'hyperparamètre . . . 16
3.4 Évaluation du classifieur final . . . 19

4 Classifieur 2 : Régression Logistique **21**
4.1 Principe et justification . . . 21
4.2 Plan d'analyse . . . 21
4.3 Implémentation . . . 21
4.4 Évaluation du classifieur final . . . 21

5 Comparaison et choix final **23**

6 Conclusion et pistes d'amélioration **25**

7 Déclaration d'utilisation de l'IA **25**

8 Contributions de chacun **25**

9 Bibliographie **26**

```r
library(tidyverse)
library(ggplot2)
library(caret)
library(naivebayes)
library(pROC)
library(knitr)
```

```r
library(kableExtra)
library(corrplot)
```

```r
data <- read.csv("credit_risk_dataset.csv")
```

1 Introduction et présentation du jeu de données

Le risque de crédit constitue l'un des enjeux majeurs des institutions financières modernes. Accorder un prêt à un emprunteur qui ne pourra pas le rembourser expose la banque à des pertes potentiellement importantes, tandis qu'un système trop restrictif pénalise des clients solvables et réduit la rentabilité. Dans ce contexte, les modèles de classification supervisée offrent un outil précieux : ils permettent d'automatiser et d'objectiver l'évaluation du risque à partir de données historiques sur les emprunteurs.

Ce rapport s'inscrit dans le cadre d'un projet de classification supervisée. Nous y construisons et évaluons deux modèles prédictifs - un classifieur Naïve Bayes et une régression logistique - afin de prédire la probabilité qu'un emprunteur soit en situation de défaut de paiement. Après une présentation du jeu de données et d'une analyse exploratoire, nous décrivons les étapes de prétraitement et de feature engineering, puis nous entraînons, évaluons et comparons les deux classifieurs. Nous concluons par une discussion critique des résultats et des limites de chaque approche.

1.1 Présentation générale

1.1.1 Contexte et objectif

Un **défaut de paiement** survient lorsqu'un emprunteur ne respecte pas ses obligations contractuelles de remboursement - que ce soit en raison d'une insolvabilité, d'une détérioration de sa situation financière, ou d'un événement imprévu. Pour les établissements de crédit, anticiper ces défauts est crucial : cela conditionne à la fois la tarification des prêts, la constitution de provisions réglementaires (Bâle III) et la gestion globale du portefeuille de risques.

Le jeu de données utilisé est issu de la plateforme Kaggle Credit Risk Dataset et porte sur des informations relatives à des emprunteurs particuliers. La variable cible est `loan_status` : elle prend la valeur **0** lorsque le prêt est remboursé normalement, et la valeur **1** en cas de **défaut de paiement**. L'objectif est donc de construire un classifieur binaire capable de distinguer ces deux profils à partir des caractéristiques disponibles.

1.1.2 Description des variables

Le jeu de données complet comprend **32 581 observations** et **12 variables**, dont la variable cible. Le tableau ci-dessous en présente une description synthétique.

Variable	Type	Description
`person_age`	Numérique	Âge de l'emprunteur (en années)
`person_income`	Numérique	Revenu annuel (en USD)
`person_home_ownership`	Catégorielle	Statut résidentiel (propriétaire, locataire, etc.)
`person_emp_length`	Numérique	Ancienneté professionnelle (en années)
`loan_intent`	Catégorielle	Motif du prêt (éducation, médical, immobilier, etc.)
`loan_grade`	Catégorielle	Note de risque attribuée au prêt (A à G)
`loan_amnt`	Numérique	Montant du prêt demandé (en USD)
`loan_int_rate`	Numérique	Taux d'intérêt du prêt (en %)

Variable	Type	Description
`loan_percent_income`	Numérique	Ratio montant du prêt / revenu annuel
`cb_person_default_on_file`	Catégorielle	Historique de défaut enregistré (Y/N)
`cb_person_cred_hist_length`	Numérique	Durée de l'historique de crédit (en années)
`loan_status`	Binaire	**Variable cible** : 0 = remboursement normal, 1 = défaut

Ces 12 variables couvrent les trois dimensions classiques de l'analyse crédit : le **profil socio-économique** de l'emprunteur (`person_age`, `person_income`, `person_home_ownership`, `person_emp_length`), les **caractéristiques du prêt** (`loan_intent`, `loan_grade`, `loan_amnt`, `loan_int_rate`, `loan_percent_income`) et l'**historique de crédit** (`cb_person_default_on_file`, `cb_person_cred_hist_length`).

```r
head(data)
```

```
##   person_age person_income person_home_ownership person_emp_length loan_intent
## 1         22         59000                  RENT               123    PERSONAL
## 2         21          9600                   OWN                 5   EDUCATION
## 3         25          9600              MORTGAGE                 1     MEDICAL
## 4         23         65500                  RENT                 4     MEDICAL
## 5         24         54400                  RENT                 8     MEDICAL
## 6         21          9900                   OWN                 2     VENTURE
##   loan_grade loan_amnt loan_int_rate loan_status loan_percent_income
## 1          D     35000         16.02           1                0.59
## 2          B      1000         11.14           0                0.10
## 3          C      5500         12.87           1                0.57
## 4          C     35000         15.23           1                0.53
## 5          C     35000         14.27           1                0.55
## 6          A      2500          7.14           1                0.25
##   cb_person_default_on_file cb_person_cred_hist_length
## 1                         Y                           3
## 2                         N                           2
## 3                         N                           3
## 4                         N                           2
## 5                         Y                           4
## 6                         N                           2
```

```r
dim(data)
```

```
## [1] 32581    12
```

```r
str(data)
```

```
## 'data.frame':    32581 obs. of  12 variables:
##  $ person_age                : int  22 21 25 23 24 21 26 24 24 21 ...
##  $ person_income             : int  59000 9600 9600 65500 54400 9900 77100 78956 83000 10000 ...
##  $ person_home_ownership     : chr  "RENT" "OWN" "MORTGAGE" "RENT" ...
##  $ person_emp_length         : num  123 5 1 4 8 2 8 5 8 6 ...
##  $ loan_intent               : chr  "PERSONAL" "EDUCATION" "MEDICAL" "MEDICAL" ...
##  $ loan_grade                : chr  "D" "B" "C" "C" ...
##  $ loan_amnt                 : int  35000 1000 5500 35000 35000 2500 35000 35000 35000 1600 ...
##  $ loan_int_rate             : num  16 11.1 12.9 15.2 14.3 ...
```

```
##  $ loan_status               : int  1 0 1 1 1 1 1 1 1 1 ...
##  $ loan_percent_income       : num  0.59 0.1 0.57 0.53 0.55 0.25 0.45 0.44 0.42 0.16 ...
##  $ cb_person_default_on_file : chr  "Y" "N" "N" "N" ...
##  $ cb_person_cred_hist_length: int  3 2 3 2 4 2 3 4 2 3 ...
```

```r
summary(data)
```

```
##    person_age     person_income     person_home_ownership person_emp_length
##  Min.   : 20.00   Min.   :   4000   Length:32581          Min.   :  0.00
##  1st Qu.: 23.00   1st Qu.:  38500   Class :character      1st Qu.:  2.00
##  Median : 26.00   Median :  55000   Mode  :character      Median :  4.00
##  Mean   : 27.73   Mean   :  66075                         Mean   :  4.79
##  3rd Qu.: 30.00   3rd Qu.:  79200                         3rd Qu.:  7.00
##  Max.   :144.00   Max.   :6000000                         Max.   :123.00
##                                                           NA's   :895
##  loan_intent         loan_grade          loan_amnt     loan_int_rate
##  Length:32581       Length:32581       Min.   :  500   Min.   : 5.42
##  Class :character   Class :character   1st Qu.: 5000   1st Qu.: 7.90
##  Mode  :character   Mode  :character   Median : 8000   Median :10.99
##                                        Mean   : 9589   Mean   :11.01
##                                        3rd Qu.:12200   3rd Qu.:13.47
##                                        Max.   :35000   Max.   :23.22
##                                                        NA's   :3116
##   loan_status     loan_percent_income cb_person_default_on_file
##  Min.   :0.0000   Min.   :0.0000      Length:32581
##  1st Qu.:0.0000   1st Qu.:0.0900      Class :character
##  Median :0.0000   Median :0.1500      Mode  :character
##  Mean   :0.2182   Mean   :0.1702
##  3rd Qu.:0.0000   3rd Qu.:0.2300
##  Max.   :1.0000   Max.   :0.8300
##
##  cb_person_cred_hist_length
##  Min.   : 2.000
##  1st Qu.: 3.000
##  Median : 4.000
##  Mean   : 5.804
##  3rd Qu.: 8.000
##  Max.   :30.000
##
```

1.2 Vérification des âges aberrants

```r
# Personnes avec un âge < 18 ans
age_moins_18 <- data[data$person_age < 18, "person_age"]
cat("Nombre de personnes avec un âge < 18 ans :", length(age_moins_18), "\n")
```

```
## Nombre de personnes avec un âge < 18 ans : 0
```

```r
if (length(age_moins_18) > 0) print(age_moins_18)

# Personnes avec un âge > 100 ans
age_plus_100 <- data[data$person_age > 100, "person_age"]
cat("Nombre de personnes avec un âge > 100 ans :", length(age_plus_100), "\n")
```

```
## Nombre de personnes avec un âge > 100 ans : 5
```

```r
if (length(age_plus_100) > 0) print(age_plus_100)
```

```
## [1] 144 144 123 123 144
```

1.3 Valeurs manquantes

Avant toute analyse, nous identifions les variables présentant des valeurs manquantes.

```r
na_counts <- colSums(is.na(data))
na_df <- data.frame(
  Variable       = names(na_counts),
  Manquants      = as.integer(na_counts),
  Pourcentage    = round(100 * na_counts / nrow(data), 2)
)
na_df <- na_df[na_df$Manquants > 0, ]
kable(na_df, row.names = FALSE,
      caption = "Variables présentant des valeurs manquantes") %>%
  kable_styling(latex_options = "HOLD_position")
```

Table 2: Variables présentant des valeurs manquantes

Variable	Manquants	Pourcentage
person_emp_length	895	2.75
loan_int_rate	3116	9.56

Deux variables contiennent des valeurs manquantes : `loan_int_rate` (~9,6 %) et `person_emp_length` (~2,7 %). Ces valeurs seront imputées par la médiane lors de l'étape de prétraitement, afin de ne pas perdre d'observations.

1.4 Distribution de la variable cible

```r
freq_cible <- prop.table(table(data$loan_status))
cat("Distribution de loan_status :\n")
```

```
## Distribution de loan_status :
```

```r
print(round(freq_cible * 100, 1))
```

```
##
##    0    1
## 78.2 21.8
```

```r
ggplot(data, aes(x = factor(loan_status,
                            labels = c("Non-défaut (0)", "Défaut (1)")))) +
  geom_bar(aes(y = after_stat(count) / sum(after_stat(count))),
           fill = c("steelblue", "tomato"), width = 0.5) +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(title = "Distribution de la variable cible loan_status",
       x = NULL, y = "Proportion") +
  theme_minimal(base_size = 12)
```

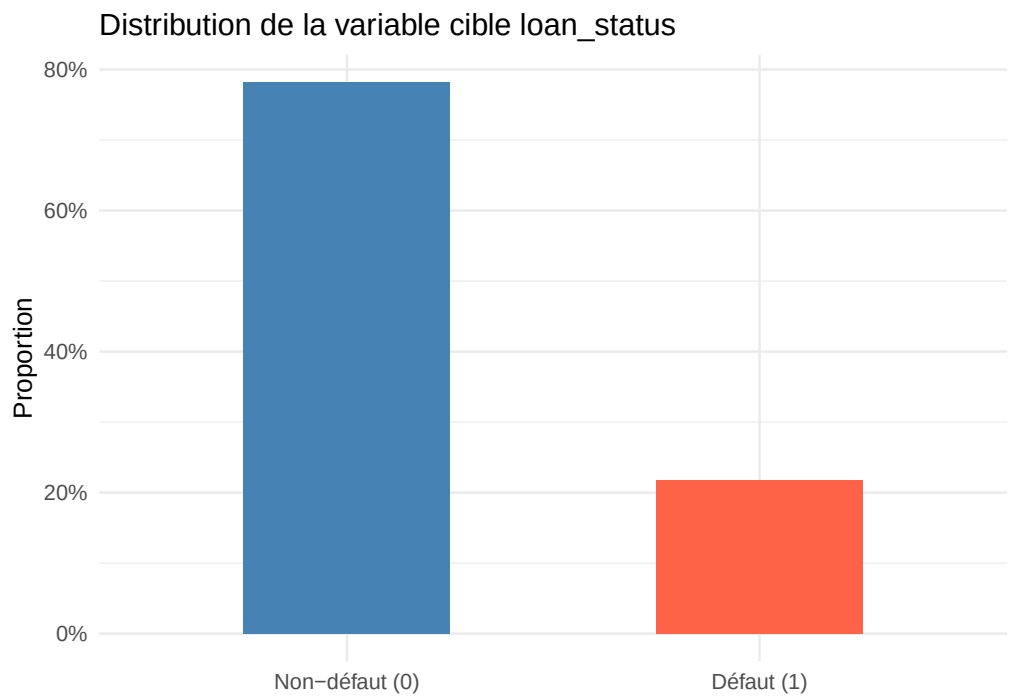

La variable cible présente un **déséquilibre notable** : environ 78 % des observations correspondent à des remboursements normaux et 22 % à des défauts. Ce déséquilibre devra être pris en compte lors de l'évaluation des classifieurs : l'accuracy seule sera insuffisante ; nous privilégierons également le **recall** (sensibilité) afin de minimiser les défauts non détectés (faux négatifs), dont le coût métier est élevé.

1.5 Analyse univariée

1.5.1 Variables quantitatives

```
vars_quant <- c("person_age", "person_income", "person_emp_length",
                "loan_amnt", "loan_int_rate", "loan_percent_income",
                "cb_person_cred_hist_length")

# Statistiques descriptives
stats_quant <- data %>%
  select(all_of(vars_quant)) %>%
  pivot_longer(everything(), names_to = "Variable", values_to = "Valeur") %>%
  group_by(Variable) %>%
  summarise(
    n       = sum(!is.na(Valeur)),
    Moyenne = round(mean(Valeur, na.rm = TRUE), 2),
    Médiane = round(median(Valeur, na.rm = TRUE), 2),
    Éc.type = round(sd(Valeur, na.rm = TRUE), 2),
    Min     = round(min(Valeur, na.rm = TRUE), 2),
    Max     = round(max(Valeur, na.rm = TRUE), 2)
  )
kable(stats_quant, caption = "Statistiques descriptives des variables quantitatives") %>%
  kable_styling(latex_options = c("HOLD_position", "scale_down"))
```

Table 3: Statistiques descriptives des variables quantitatives

Variable	n	Moyenne	Médiane	Éc.type	Min	Max
cb_person_cred_hist_length	32581	5.80	4.00	4.06	2.00	3.000e+01
loan_amnt	32581	9589.37	8000.00	6322.09	500.00	3.500e+04
loan_int_rate	29465	11.01	10.99	3.24	5.42	2.322e+01
loan_percent_income	32581	0.17	0.15	0.11	0.00	8.300e-01
person_age	32581	27.73	26.00	6.35	20.00	1.440e+02
person_emp_length	31686	4.79	4.00	4.14	0.00	1.230e+02
person_income	32581	66074.85	55000.00	61983.12	4000.00	6.000e+06

```r
# Histogrammes
data %>%
  select(all_of(vars_quant)) %>%
  pivot_longer(everything(), names_to = "Variable", values_to = "Valeur") %>%
  ggplot(aes(x = Valeur)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha = 0.8) +
  facet_wrap(~ Variable, scales = "free", ncol = 2) +
  labs(title = "Distribution des variables quantitatives", x = NULL, y = "Effectif") +
  theme_minimal(base_size = 10)
```

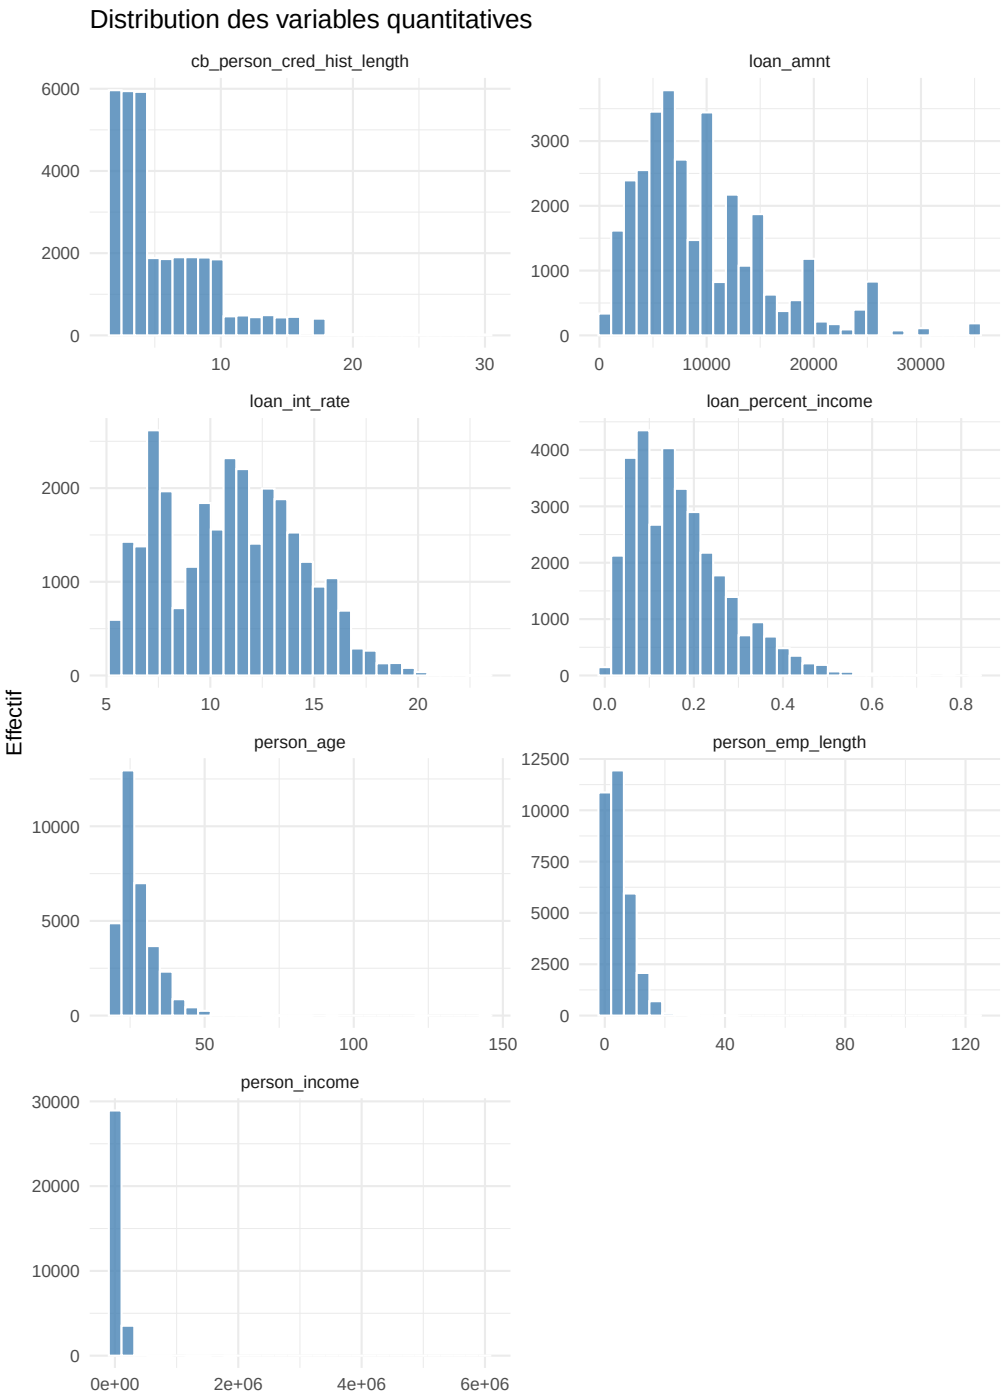

Plusieurs observations méritent d'être soulignées. La variable `person_income` présente une distribution très asymétrique vers la droite, avec quelques valeurs extrêmes très élevées (revenus > 1 000 000 USD), vraisemblablement des erreurs de saisie. De même, `person_emp_length` affiche une valeur maximale de 123 ans, manifestement aberrante. Ces valeurs extrêmes n'ont pas été supprimées afin de conserver la taille de l'échantillon, mais leur influence sur les modèles sera discutée. Le taux d'intérêt `loan_int_rate` suit une distribution approximativement gaussienne, centrée autour de 11 %.

1.5.2 Variables qualitatives

```r
vars_qual <- c("person_home_ownership", "loan_intent",
               "loan_grade", "cb_person_default_on_file")

# Tableau de fréquences pour chaque variable
for (v in vars_qual) {
  freq_v <- sort(table(data[[v]]), decreasing = TRUE)
  df_v   <- data.frame(
    Modalité    = names(freq_v),
    Effectif    = as.integer(freq_v),
    Fréquence   = paste0(round(100 * freq_v / sum(freq_v), 1), " %")
  )
  print(kable(df_v, row.names = FALSE,
              caption = paste("Répartition de", gsub("_", " ", v))) %>%
          kable_styling(latex_options = "HOLD_position"))
  cat("\n\n")
}
```

Table 4: Répartition de person home ownership

Modalité	Effectif	Fréquence
RENT	16446	50.5 %
MORTGAGE	13444	41.3 %
OWN	2584	7.9 %
OTHER	107	0.3 %

Table 5: Répartition de loan intent

Modalité	Effectif	Fréquence
EDUCATION	6453	19.8 %
MEDICAL	6071	18.6 %
VENTURE	5719	17.6 %
PERSONAL	5521	16.9 %
DEBTCONSOLIDATION	5212	16 %
HOMEIMPROVEMENT	3605	11.1 %

Table 6: Répartition de loan grade

Modalité	Effectif	Fréquence
A	10777	33.1 %
B	10451	32.1 %
C	6458	19.8 %
D	3626	11.1 %
E	964	3 %
F	241	0.7 %
G	64	0.2 %

Table 7: Répartition de cb person default on file

Modalité	Effectif	Fréquence
N	26836	82.4 %
Y	5745	17.6 %

```r
# Diagrammes en barres
data %>%
  select(all_of(vars_qual)) %>%
  pivot_longer(everything(), names_to = "Variable", values_to = "Modalité") %>%
  ggplot(aes(x = Modalité)) +
  geom_bar(fill = "steelblue", alpha = 0.8) +
  facet_wrap(~ Variable, scales = "free", ncol = 2) +
  labs(title = "Distribution des variables qualitatives", x = NULL, y = "Effectif") +
  theme_minimal(base_size = 10) +
  theme(axis.text.x = element_text(angle = 30, hjust = 1))
```

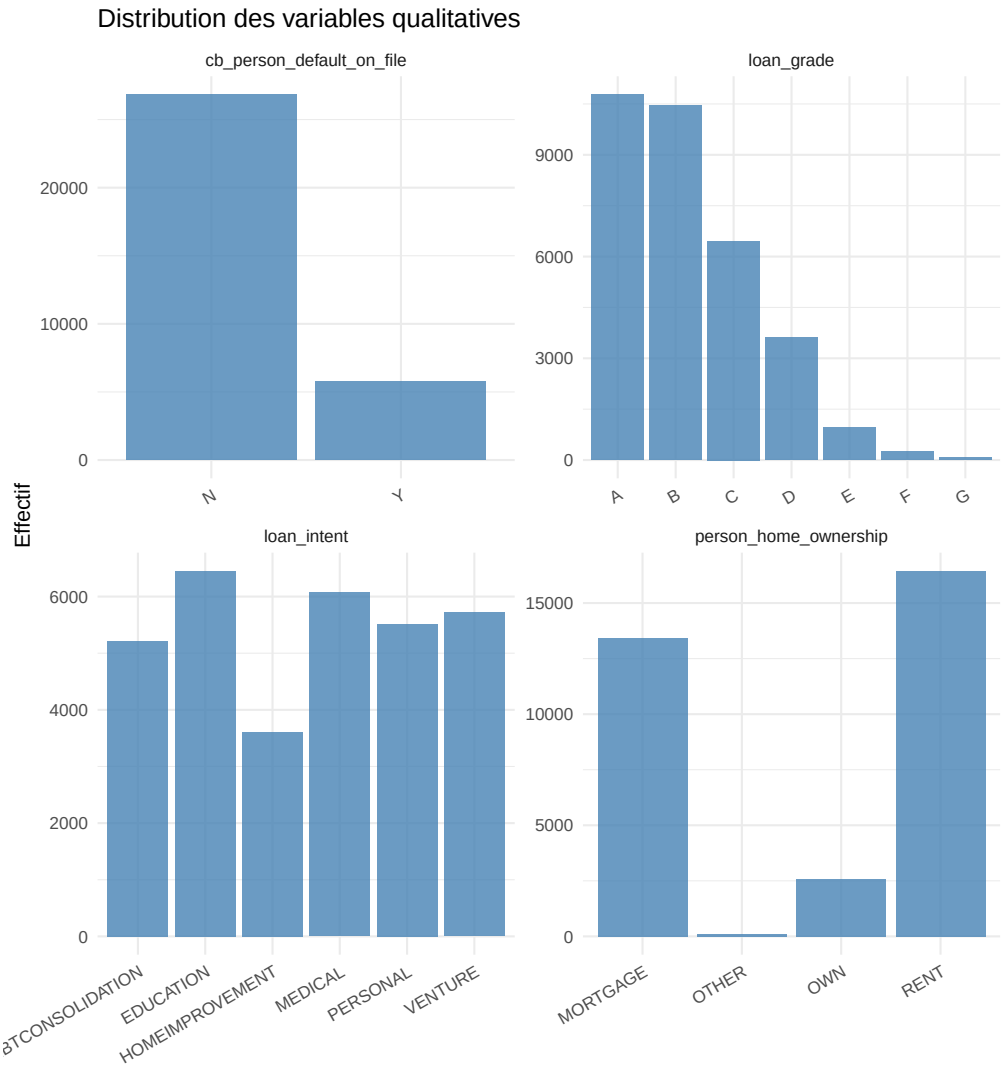

La majorité des emprunteurs sont **locataires** (`RENT`, ~50 %) ou remboursent un emprunt immobilier (`MORTGAGE`, ~41 %). La note de risque `loan_grade` est concentrée sur les classes A et B (profils les moins risqués). Environ

17 % des individus ont un historique de défaut enregistré (`cb_person_default_on_file = Y`).

1.6 Analyse multivariée

1.6.1 Matrice de corrélation

```
cor_mat <- cor(data %>% select(all_of(vars_quant)), use = "complete.obs")
corrplot(cor_mat, method = "color", type = "upper",
         tl.cex = 0.8, addCoef.col = "black", number.cex = 0.65,
         title = "Matrice de corrélation des variables quantitatives",
         mar = c(0, 0, 1, 0))
```

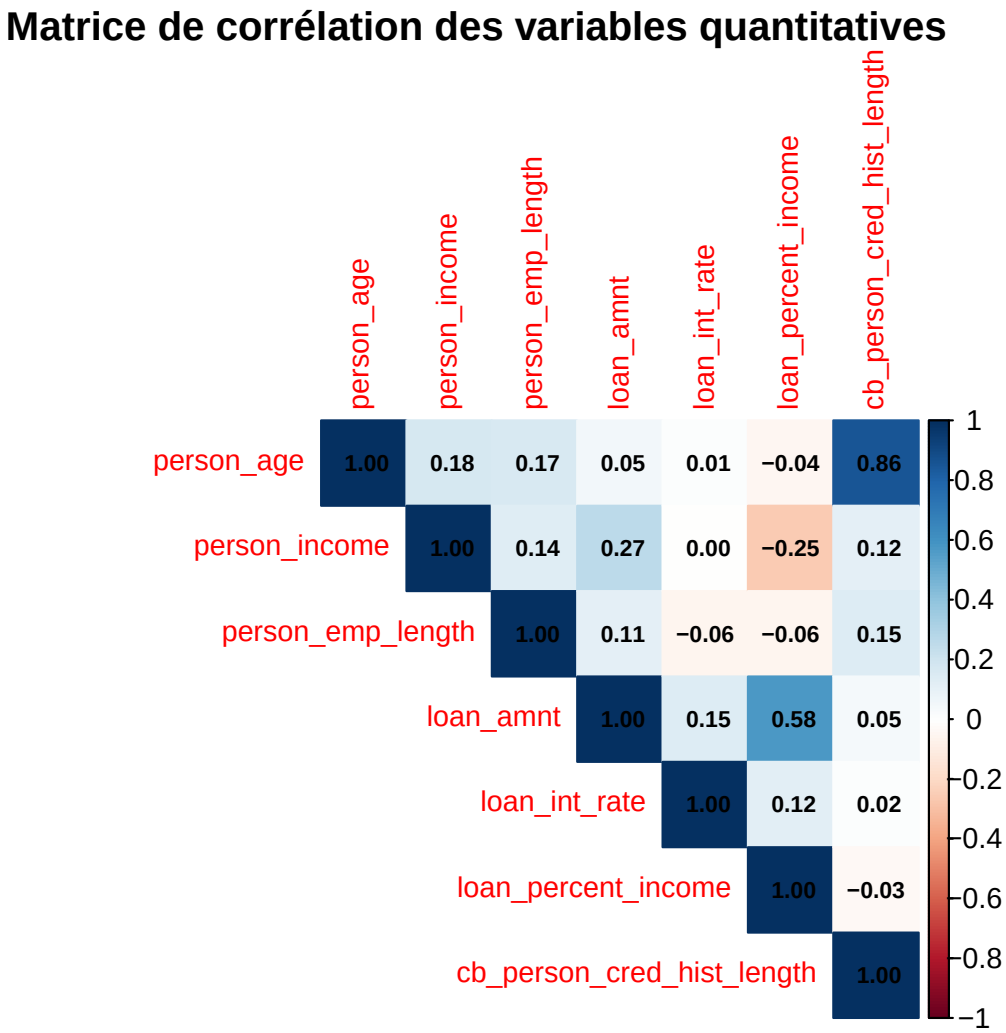

On observe une corrélation positive modérée entre `loan_int_rate` et `loan_percent_income` (~0,12), ce qui est cohérent : les emprunteurs présentant un ratio prêt/revenu élevé se voient attribuer des taux plus élevés. La corrélation entre `loan_amnt` et `loan_percent_income` est également positive (~0,58), logiquement.

1.6.2 Variables quantitatives

```
data %>%
  select(all_of(vars_quant), loan_status) %>%
  mutate(loan_status = factor(loan_status,
```

```r
                              labels = c("Non-défaut", "Défaut"))) %>%
  pivot_longer(-loan_status, names_to = "Variable", values_to = "Valeur") %>%
  ggplot(aes(x = loan_status, y = Valeur, fill = loan_status)) +
  geom_boxplot(outlier.size = 0.5, alpha = 0.7) +
  scale_fill_manual(values = c("steelblue", "tomato")) +
  facet_wrap(~ Variable, scales = "free_y", ncol = 2) +
  labs(title = "Variables quantitatives selon le statut du prêt",
       x = NULL, y = NULL, fill = "Statut") +
  theme_minimal(base_size = 10) +
  theme(legend.position = "bottom")
```

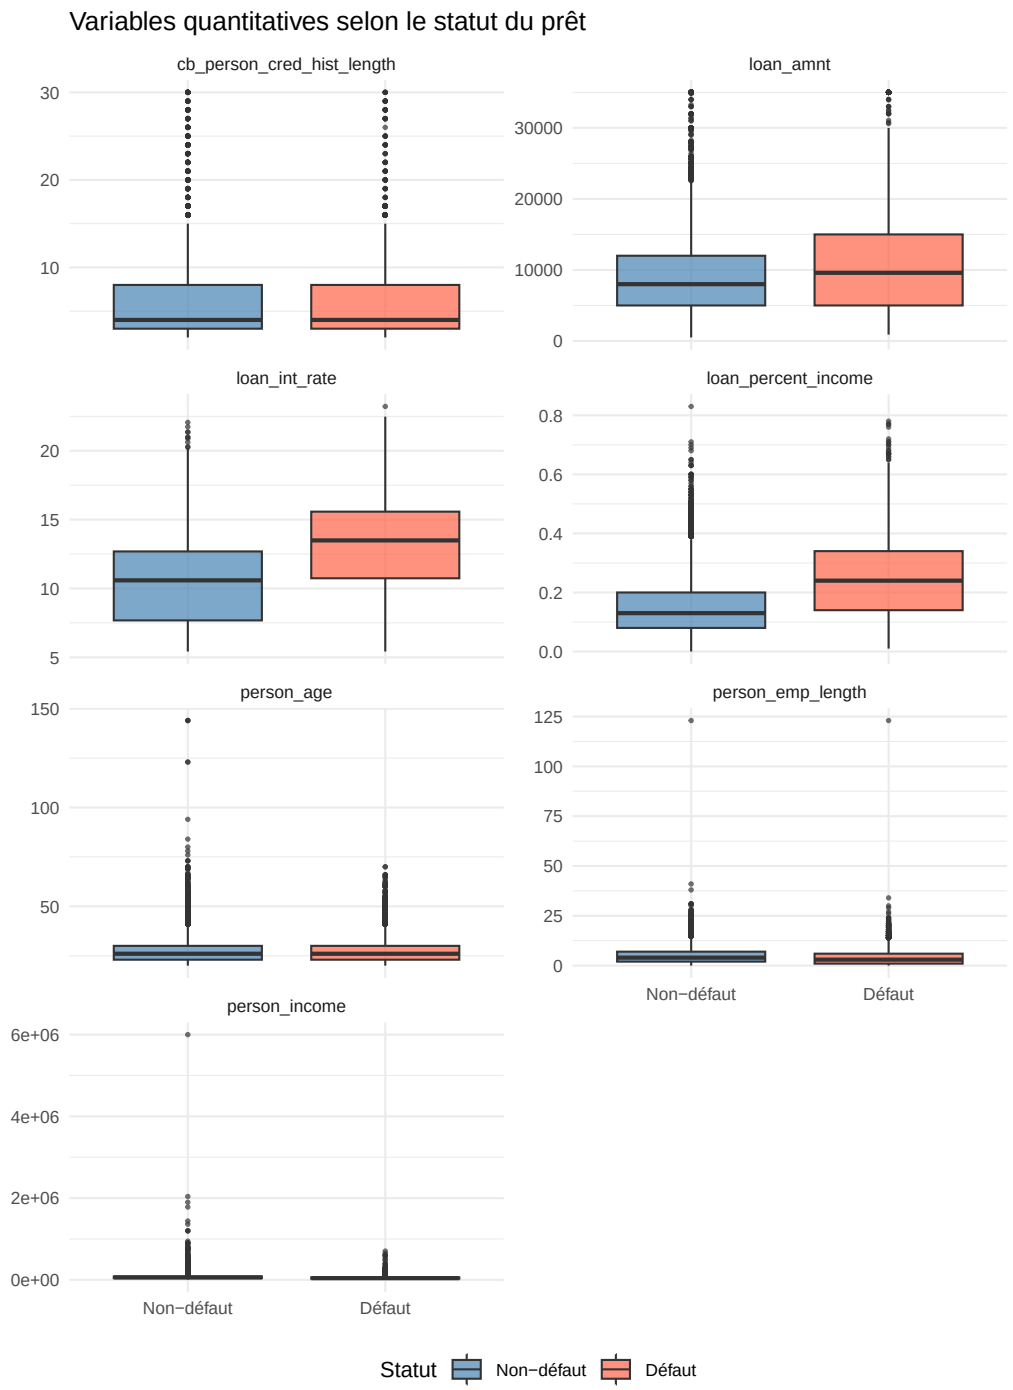

Les défauts sont associés à des **taux d'intérêt plus élevés**, un **ratio prêt/revenu plus élevé** et un `loan_int_rate` médian supérieur. Ces variables apparaissent donc discriminantes pour la classification.

1.6.3 Variables qualitatives

```
data %>%
  select(all_of(vars_qual), loan_status) %>%
  mutate(loan_status = factor(loan_status,
                              labels = c("Non-défaut", "Défaut"))) %>%
  pivot_longer(-loan_status, names_to = "Variable", values_to = "Modalité") %>%
```

```r
ggplot(aes(x = Modalité, fill = loan_status)) +
geom_bar(position = "fill", alpha = 0.85) +
scale_y_continuous(labels = scales::percent_format()) +
scale_fill_manual(values = c("steelblue", "tomato")) +
facet_wrap(~ Variable, scales = "free_x", ncol = 2) +
labs(title = "Proportion de défauts par modalité des variables qualitatives",
     x = NULL, y = "Proportion", fill = "Statut") +
theme_minimal(base_size = 10) +
theme(axis.text.x = element_text(angle = 30, hjust = 1),
      legend.position = "bottom")
```

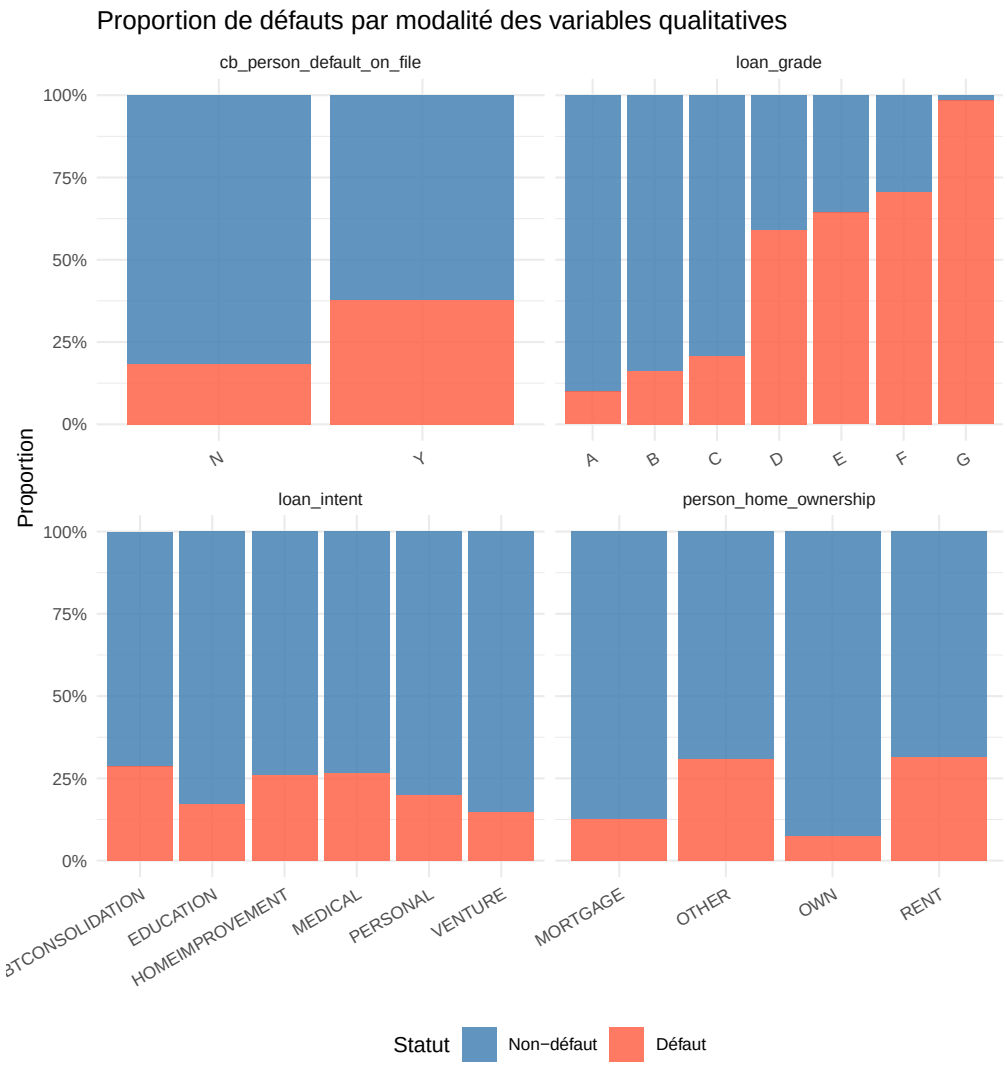

Les emprunteurs avec une **note de risque F ou G** présentent des taux de défaut nettement plus élevés que ceux notés A ou B. De même, les individus ayant un **historique de défaut** (`cb_person_default_on_file = Y`) sont proportionnellement plus nombreux à être en défaut. La note `loan_grade` et l'historique de défaut apparaissent comme des variables particulièrement informatives pour nos classifieurs.

2 Prétraitement des données

À l'issue de l'analyse exploratoire, les étapes de prétraitement suivantes sont nécessaires avant la modélisation :

1. **Suppression des âges aberrants** : les 5 observations avec `person_age > 100` sont retirées (vraisemblables erreurs de saisie, représentent $< 0{,}02$ % de l'échantillon).
2. **Conversion de la variable cible** `loan_status` en facteur à deux niveaux.
3. **Conversion des variables qualitatives** en facteurs.
4. **Découpage train/test** (80 %/20 %) stratifié sur `loan_status` - **effectué avant toute imputation et feature engineering** pour éviter tout data leakage.
5. **Imputation des valeurs manquantes** par la médiane calculée **sur le train uniquement**, puis appliquée au test. Cela garantit que le test ne fournit aucune information au processus d'entraînement.
6. **Feature engineering** (après imputation) : création de deux nouvelles variables explicatives appliquées séparément sur train et test (détaillé ci-dessous).

2.1 Feature engineering

L'analyse exploratoire a mis en évidence deux relations particulièrement importantes : le taux d'intérêt et le ratio prêt/revenu sont tous deux discriminants, et les grades D à G concentrent les défauts. Nous en dérivons deux variables supplémentaires :

- **`risk_score`** : produit de `loan_percent_income` par `loan_int_rate`. Cette variable capture la **charge financière combinée** - un emprunteur avec un ratio prêt/revenu élevé *et* un taux élevé supporte un fardeau démultiplié. L'interaction n'est pas linéairement redondante avec les deux variables séparées.
- **`high_risk_grade`** : indicateur binaire valant 1 si la note du prêt appartient aux classes D, E, F ou G (grades les plus risqués), 0 sinon. Ce regroupement est justifié par la forte discontinuité du taux de défaut observée entre les classes C et D dans l'analyse exploratoire.

```r
set.seed(42)

# -- Étape 1 : nettoyage des âges aberrants -----------------------------------
n_avant <- nrow(data)
data <- data[data$person_age <= 100, ]
cat("Observations supprimées (âge > 100) :", n_avant - nrow(data), "\n")
```

```
## Observations supprimées (âge > 100) : 5
```

```r
cat("Taille du jeu de données après nettoyage :", nrow(data), "\n")
```

```
## Taille du jeu de données après nettoyage : 32576
```

```r
# -- Étape 2 : conversion de la variable cible et des variables qualitatives ---
data$loan_status <- factor(data$loan_status, levels = c(0, 1),
                           labels = c("NonDefaut", "Defaut"))
data$person_home_ownership     <- factor(data$person_home_ownership)
data$loan_intent               <- factor(data$loan_intent)
data$loan_grade                <- factor(data$loan_grade,
                                         levels = c("A","B","C","D","E","F","G"))
data$cb_person_default_on_file <- factor(data$cb_person_default_on_file)

# -- Étape 3 : découpage stratifié AVANT imputation et feature engineering -----
# Indispensable pour éviter tout data leakage vers le jeu de test.
index_train <- createDataPartition(data$loan_status, p = 0.8, list = FALSE)
train <- data[ index_train, ]
test  <- data[-index_train, ]
```

```r
cat("Taille train :", nrow(train),
    "| Taille test :", nrow(test), "\n")
```

```
## Taille train : 26062 | Taille test : 6514
```

```r
prop.table(table(train$loan_status))
```

```
##
## NonDefaut    Defaut
## 0.7817896 0.2182104
```

```r
prop.table(table(test$loan_status))
```

```
##
## NonDefaut    Defaut
## 0.7818545 0.2181455
```

```r
# -- Étape 4 : imputation par la médiane du TRAIN uniquement ------------------

med_int_rate   <- median(train$loan_int_rate,    na.rm = TRUE)
med_emp_length <- median(train$person_emp_length, na.rm = TRUE)

train$loan_int_rate[is.na(train$loan_int_rate)]         <- med_int_rate
train$person_emp_length[is.na(train$person_emp_length)] <- med_emp_length
test$loan_int_rate[is.na(test$loan_int_rate)]           <- med_int_rate
test$person_emp_length[is.na(test$person_emp_length)]   <- med_emp_length

cat("Médiane loan_int_rate (train) :", med_int_rate, "\n")
```

```
## Médiane loan_int_rate (train) : 10.99
```

```r
cat("Médiane person_emp_length (train) :", med_emp_length, "\n")
```

```
## Médiane person_emp_length (train) : 4
```

```r
cat("Valeurs manquantes restantes - train :", sum(is.na(train)), "\n")
```

```
## Valeurs manquantes restantes - train : 0
```

```r
cat("Valeurs manquantes restantes - test  :", sum(is.na(test)),  "\n")
```

```
## Valeurs manquantes restantes - test  : 0
```

```r
# -- Étape 5 : feature engineering (après imputation, sans statistique externe)

train <- train %>%
  mutate(
    risk_score      = loan_percent_income * loan_int_rate,
    high_risk_grade = as.integer(loan_grade %in% c("D", "E", "F", "G"))
  )
test <- test %>%
  mutate(
    risk_score      = loan_percent_income * loan_int_rate,
    high_risk_grade = as.integer(loan_grade %in% c("D", "E", "F", "G"))
  )
cat("Variables créées : risk_score, high_risk_grade\n")
```

```
## Variables créées : risk_score, high_risk_grade
```

```r
cat("Valeurs manquantes finales - train :", sum(is.na(train)), "\n")
```

```
## Valeurs manquantes finales - train : 0
```

```r
cat("Valeurs manquantes finales - test  :", sum(is.na(test)),  "\n")
```

```
## Valeurs manquantes finales - test  : 0
```

Le découpage stratifié garantit que la proportion de défauts est similaire dans les ensembles d'entraînement et de test, ce qui assure la comparabilité des évaluations. `caret` gère automatiquement l'encodage *dummy* des variables catégorielles pour la régression logistique via son mécanisme interne de prétraitement.

3 Classifieur 1 : Naïve Bayes

3.1 Principe et justification

Le classifieur **Naïve Bayes** repose sur le théorème de Bayes en supposant l'**indépendance conditionnelle** des variables explicatives sachant la classe :

$$P(\text{Défaut} \mid x_1, \ldots, x_p) \propto P(\text{Défaut}) \prod_{j=1}^{p} P(x_j \mid \text{Défaut})$$

Chaque vraisemblance $P(x_j \mid C)$ est estimée empiriquement : par une loi gaussienne pour les variables continues, et par comptage de fréquences pour les variables catégorielles. Le **lissage de Laplace** (paramètre λ) est appliqué aux fréquences catégorielles afin d'éviter les probabilités nulles lorsqu'une modalité n'apparaît pas dans un pli de validation.

Nous avons retenu Naïve Bayes pour les raisons suivantes :

- **Efficacité computationnelle** : l'estimation se réduit à des statistiques univariées par classe, ce qui le rend très rapide même sur des données de grande dimension.
- **Gestion native des variables mixtes** : les variables continues et catégorielles sont modélisées séparément, sans encodage *dummy* ni normalisation imposée.
- **Bon comportement avec peu de données** : grâce à sa faible variance, Naïve Bayes généralise bien lorsque l'échantillon d'apprentissage est limité.
- **Baseline probabiliste solide** : il fournit des probabilités a posteriori directement exploitables pour ajuster un seuil de décision selon le coût métier.

3.2 Plan d'analyse

L'hyperparamètre principal est le **paramètre de lissage de Laplace** λ (alias `laplace`) : une valeur nulle donne les fréquences brutes (risque de probabilité zéro), tandis qu'une valeur positive lisse les distributions catégorielles.

Métrique d'évaluation : l'**AUC-ROC** est utilisée pour sélectionner le λ optimal, complétée par le **recall** pour quantifier la détection des vrais défauts.

3.3 Implémentation et choix de l'hyperparamètre

```r
ctrl <- trainControl(method          = "cv",
                     number          = 10,
                     classProbs      = TRUE,
                     summaryFunction = twoClassSummary,
                     savePredictions = "final")
```

```r
grid_nb <- expand.grid(laplace   = c(0, 0.5, 1, 2, 5),
                       usekernel = FALSE,
                       adjust    = 1)

set.seed(42)
nb_cv <- train(loan_status ~ .,
               data      = train,
               method    = "naive_bayes",
               trControl = ctrl,
               tuneGrid  = grid_nb,
               metric    = "ROC")

plot(nb_cv,
     main = "AUC-ROC en fonction du paramètre de lissage de Laplace")
```

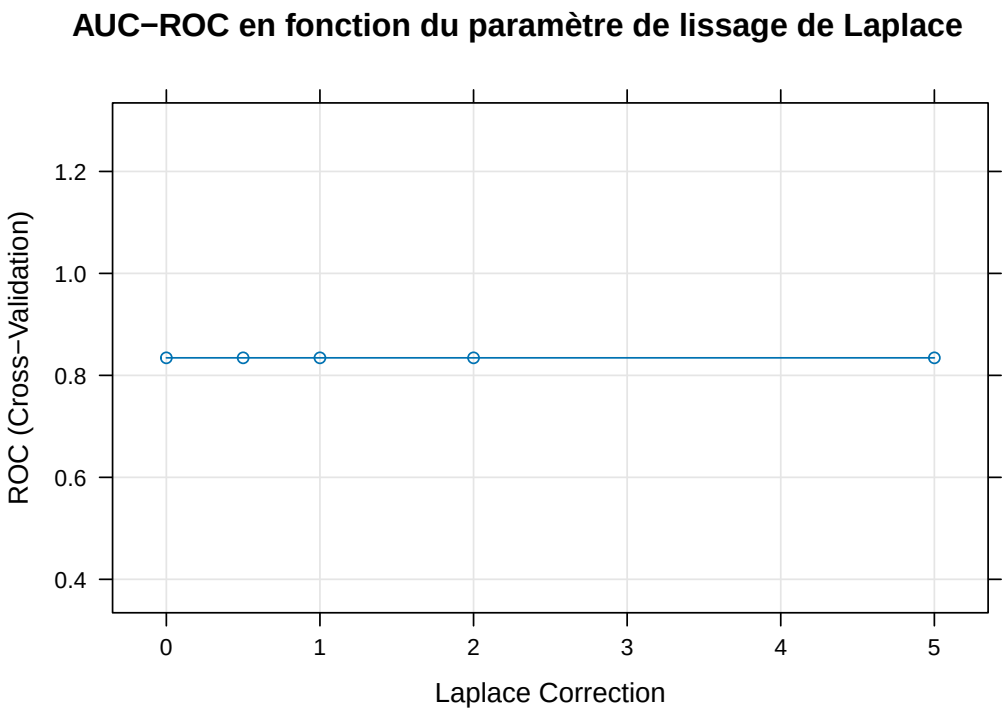


```r
cat("Meilleur laplace :", nb_cv$bestTune$laplace, "\n")
```

```
## Meilleur laplace : 0
```

```r
nb_final <- naive_bayes(loan_status ~ ., data = train,
                        laplace = nb_cv$bestTune$laplace)
print(nb_final)
```

```
##
## ================================ Naive Bayes ==================================
##
## Call:
## naive_bayes.formula(formula = loan_status ~ ., data = train,
##     laplace = nb_cv$bestTune$laplace)
##
## -------------------------------------------------------------------------------
##
```

```
## Laplace smoothing: 0
##
## -------------------------------------------------------------------------------
##
## A priori probabilities:
##
## NonDefaut    Defaut
## 0.7817896 0.2182104
##
## -------------------------------------------------------------------------------
##
## Tables:
##
## -------------------------------------------------------------------------------
## :: person_age (Gaussian)
## -------------------------------------------------------------------------------
##
## person_age NonDefaut    Defaut
##       mean 27.796613 27.488658
##       sd    6.231840  6.287057
##
## -------------------------------------------------------------------------------
## :: person_income (Gaussian)
## -------------------------------------------------------------------------------
##
## person_income NonDefaut   Defaut
##          mean  70650.92 49281.04
##          sd    55601.52 37439.46
##
## -------------------------------------------------------------------------------
## :: person_home_ownership (Categorical)
## -------------------------------------------------------------------------------
##
## person_home_ownership   NonDefaut      Defaut
##              MORTGAGE 0.462429448 0.244768771
##              OTHER    0.003042945 0.004747670
##              OWN      0.094527607 0.026551785
##              RENT     0.440000000 0.723931774
##
## -------------------------------------------------------------------------------
## :: person_emp_length (Gaussian)
## -------------------------------------------------------------------------------
##
## person_emp_length NonDefaut   Defaut
##              mean  4.931828 4.164586
##              sd    4.079691 4.132308
##
## -------------------------------------------------------------------------------
## :: loan_intent (Categorical)
## -------------------------------------------------------------------------------
##
## loan_intent         NonDefaut    Defaut
##   DEBTCONSOLIDATION 0.1457178 0.2106559
##   EDUCATION         0.2086871 0.1538597
```

```
##   HOMEIMPROVEMENT   0.1042454 0.1343415
##   MEDICAL           0.1756564 0.2254264
##   PERSONAL          0.1741840 0.1559698
##   VENTURE           0.1915092 0.1197468
##
## ------------------------------------------------------------------------------
##
## # ... and 8 more tables
##
## ------------------------------------------------------------------------------
```

3.4 Évaluation du classifieur final

```r
pred_nb      <- predict(nb_final, newdata = test)
pred_nb_prob <- predict(nb_final, newdata = test, type = "prob")[, "Defaut"]

cm_nb <- confusionMatrix(pred_nb, test$loan_status, positive = "Defaut")
print(cm_nb)
```

```
## Confusion Matrix and Statistics
##
##            Reference
## Prediction  NonDefaut Defaut
##   NonDefaut      4517    472
##   Defaut          576    949
##
##                Accuracy : 0.8391
##                  95% CI : (0.83, 0.848)
##     No Information Rate : 0.7819
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.5405
##
##  Mcnemar's Test P-Value : 0.001464
##
##             Sensitivity : 0.6678
##             Specificity : 0.8869
##          Pos Pred Value : 0.6223
##          Neg Pred Value : 0.9054
##              Prevalence : 0.2181
##          Detection Rate : 0.1457
##    Detection Prevalence : 0.2341
##       Balanced Accuracy : 0.7774
##
##        'Positive' Class : Defaut
##
```

```r
plot_confusion_matrix(cm_nb, "Matrice de confusion - Naïve Bayes")
```

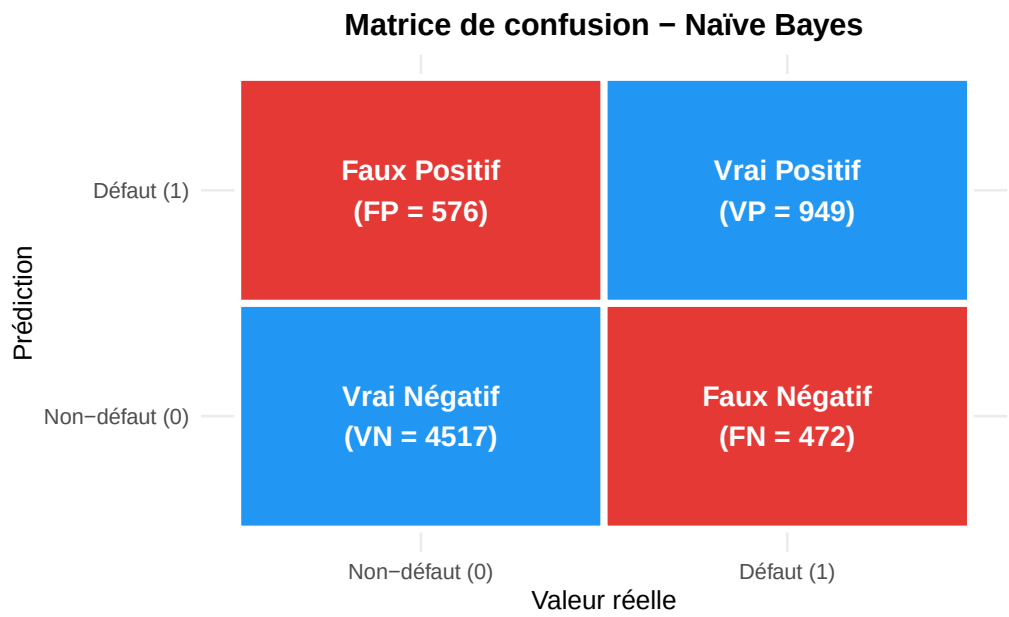


```r
roc_nb <- roc(test$loan_status, pred_nb_prob,
              levels = c("NonDefaut", "Defaut"))
plot(roc_nb, col = "steelblue", lwd = 2, legacy.axes = TRUE,
     xlim = c(1, 0), ylim = c(0, 1), xaxs = "i", yaxs = "i",
     main = paste0("Courbe ROC - Naïve Bayes (AUC = ",
                   round(auc(roc_nb), 3), ")"))
abline(a = 1, b = -1, lty = 2, col = "grey60")
```

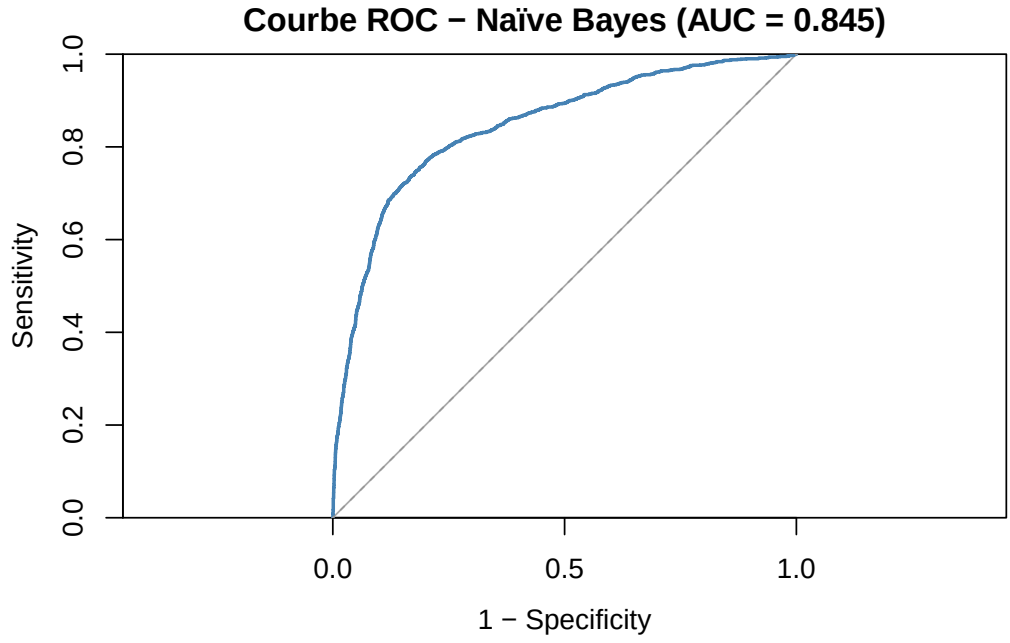

Interprétation : Le classifieur Naïve Bayes produit des probabilités a posteriori continues, exploitables pour moduler le seuil de décision. Les faux négatifs (défauts non détectés) restent la principale source d'erreur à surveiller, compte tenu du coût métier élevé de ce type d'erreur. L'hypothèse d'indépendance conditionnelle peut cependant limiter la performance lorsque des variables sont fortement corrélées (comme `loan_int_rate` et `loan_percent_income`).

4 Classifieur 2 : Régression Logistique

4.1 Principe et justification

La **régression logistique** est le modèle de référence classique pour la classification binaire, notamment dans le cadre réglementaire du risque de crédit. Elle modélise le logarithme du rapport de probabilités (*log-odds*) d'appartenir à la classe positive (le défaut) comme une combinaison linéaire des variables explicatives :

$$\log\left(\frac{P(\text{Défaut})}{1 - P(\text{Défaut})}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

La probabilité prédite est ensuite obtenue via la fonction sigmoïde. Les variables catégorielles sont automatiquement encodées en variables indicatrices (*dummy*) par `caret`.

Nous justifions ce choix par :

- **Interprétabilité directe** : l'impact de chaque variable est quantifié par son coefficient (ou l'odds-ratio associé), ce qui est précieux pour justifier un refus de crédit auprès d'un régulateur.
- **Probabilités de classe bien calibrées** : contrairement à Naïve Bayes dont les probabilités peuvent être mal calibrées sous l'hypothèse d'indépendance, les scores issus de la fonction sigmoïde sont continus et fiables pour ajuster un seuil de décision selon le coût métier.

4.2 Plan d'analyse

La régression logistique standard ne possède pas d'hyperparamètre à optimiser. La validation croisée 10 fois est utilisée **uniquement pour estimer la performance généralisable** du modèle. Les données sont centrées-réduites (`preProcess`) afin que les coefficients soient comparables entre variables.

4.3 Implémentation

```r
set.seed(42)
logit_cv <- train(loan_status ~ .,
                  data       = train,
                  method     = "glm",
                  family     = "binomial",
                  trControl  = ctrl,
                  preProcess = c("center", "scale"),
                  metric     = "ROC")

cat("AUC-ROC moyenne en validation croisée :",
    round(max(logit_cv$results$ROC), 3), "\n")
```

```
## AUC-ROC moyenne en validation croisée : 0.87
```

4.4 Évaluation du classifieur final

```r
pred_logit      <- predict(logit_cv, newdata = test)
pred_logit_prob <- predict(logit_cv, newdata = test, type = "prob")[, "Defaut"]

cm_logit <- confusionMatrix(pred_logit, test$loan_status, positive = "Defaut")
print(cm_logit)
```

```
## Confusion Matrix and Statistics
##
##            Reference
```

```
## Prediction  NonDefaut Defaut
##   NonDefaut      4869    596
##   Defaut          224    825
##
##                Accuracy : 0.8741
##                  95% CI : (0.8658, 0.8821)
##     No Information Rate : 0.7819
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.5925
##
##  Mcnemar's Test P-Value : < 2.2e-16
##
##             Sensitivity : 0.5806
##             Specificity : 0.9560
##          Pos Pred Value : 0.7865
##          Neg Pred Value : 0.8909
##              Prevalence : 0.2181
##          Detection Rate : 0.1267
##    Detection Prevalence : 0.1610
##       Balanced Accuracy : 0.7683
##
##        'Positive' Class : Defaut
##
```

```r
plot_confusion_matrix(cm_logit, "Matrice de confusion - Régression Logistique")
```

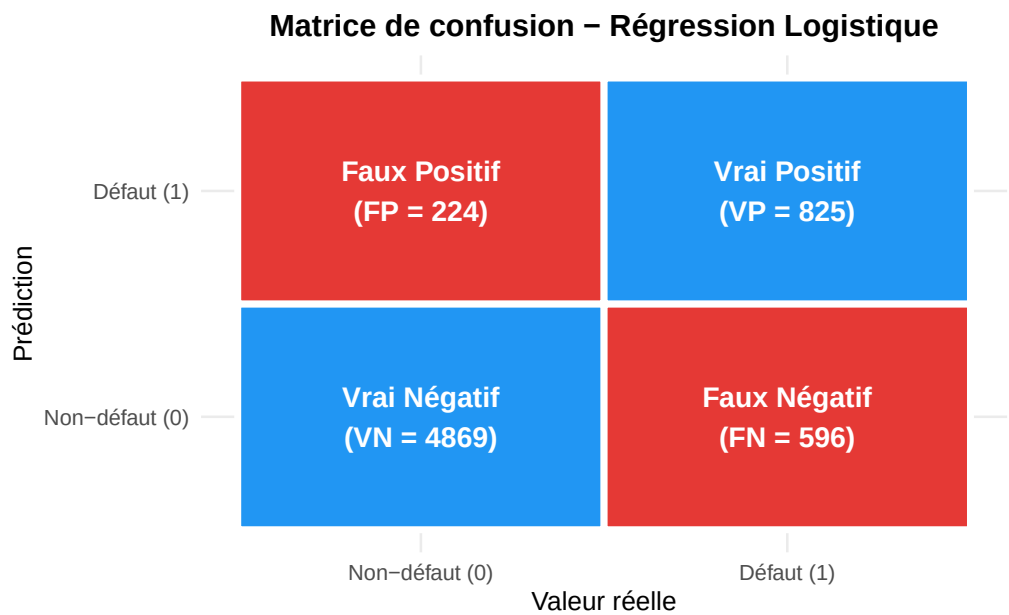


```r
roc_logit <- roc(test$loan_status, pred_logit_prob,
                 levels = c("NonDefaut", "Defaut"))
plot(roc_logit,
     col = "forestgreen", lwd = 2,
     legacy.axes = TRUE,
     xlim = c(1, 0), ylim = c(0, 1), xaxs = "i", yaxs = "i",
     main = paste0("Courbe ROC - Régression Logistique (AUC = ",
                   round(auc(roc_logit), 3), ")"))
```

```r
abline(a = 1, b = -1, lty = 2, col = "grey60")
```

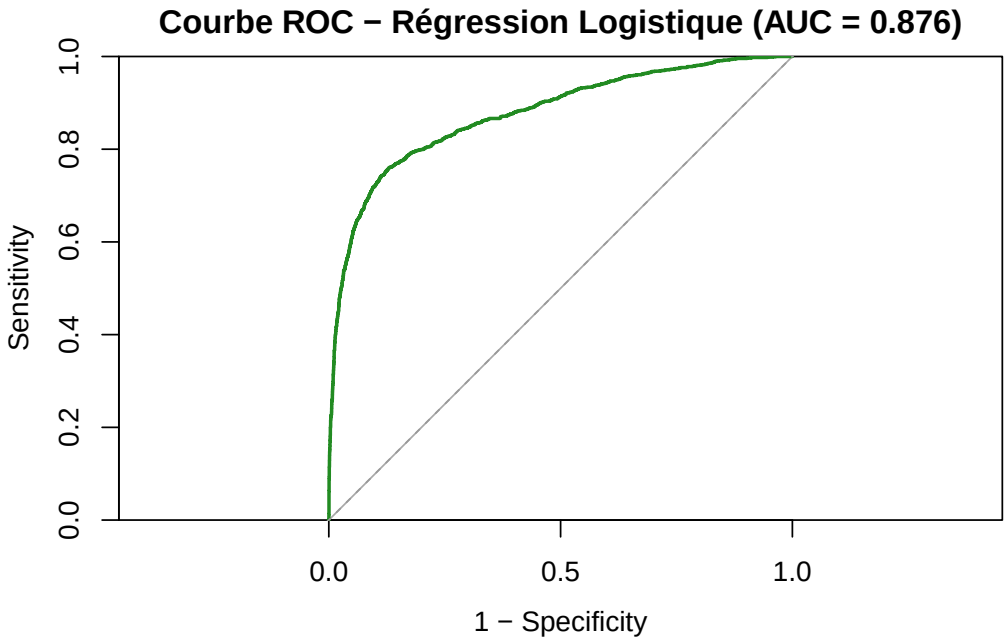

Interprétation : La régression logistique offre des probabilités bien calibrées et des coefficients directement interprétables. Le graphique des coefficients permet d'identifier les variables les plus déterminantes dans la prédiction du défaut.

5 Comparaison et choix final

```r
extract_metrics <- function(cm, roc_obj) {
  data.frame(
    Accuracy  = round(cm$overall["Accuracy"], 3),
    Recall    = round(cm$byClass["Sensitivity"], 3),
    Precision = round(cm$byClass["Pos Pred Value"], 3),
    F1        = round(cm$byClass["F1"], 3),
    AUC       = round(auc(roc_obj), 3)
  )
}

metrics <- rbind(
  extract_metrics(cm_nb, roc_nb),
  extract_metrics(cm_logit, roc_logit)
)
rownames(metrics) <- c("Naïve Bayes", "Régression Logistique")

kable(metrics, booktabs = TRUE,
      caption = "Comparaison des métriques de performance sur le jeu de test") %>%
  kable_styling(latex_options = "HOLD_position")
```

Table 8: Comparaison des métriques de performance sur le jeu de test

	Accuracy	Recall	Precision	F1	AUC
Naïve Bayes	0.839	0.668	0.622	0.644	0.845
Régression Logistique	0.874	0.581	0.786	0.668	0.876

```r
plot(roc_nb, col = "steelblue", lwd = 2, legacy.axes = TRUE,
     xlim = c(1, 0), ylim = c(0, 1), xaxs = "i", yaxs = "i",
     main = "Superposition des courbes ROC")
lines(roc_logit, col = "forestgreen", lwd = 2)
abline(a = 1, b = -1, lty = 2, col = "grey60")
legend("bottomright",
       legend = c(paste0("Naïve Bayes (AUC = ", round(auc(roc_nb), 3), ")"),
                  paste0("Régression Log. (AUC = ", round(auc(roc_logit), 3), ")")),
       col    = c("steelblue", "forestgreen"),
       lwd    = 2, bty = "n")
```

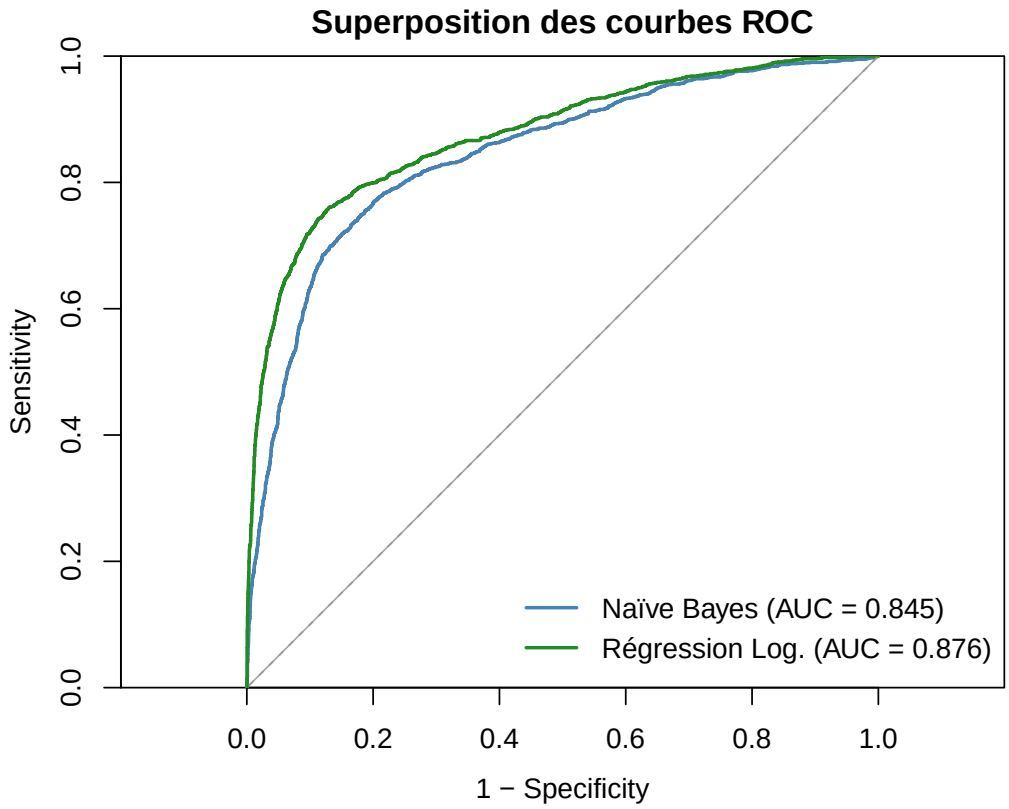

Discussion. Le classifieur Naïve Bayes est particulièrement efficace et fournit des probabilités a posteriori directement exploitables, mais son hypothèse d'indépendance conditionnelle peut le pénaliser face à des variables corrélées. La régression logistique offre une interprétation directe des coefficients et des probabilités bien calibrées, deux atouts essentiels en contexte bancaire.

Classifieur retenu : Nous recommandons la **Régression Logistique** pour les raisons suivantes : - Probabilités bien calibrées, idéales pour fixer un seuil de décision métier. - Coefficients directement interprétables et justifiables auprès d'un régulateur. - Modèle approuvé par les réglementations bancaires (Bâle III, IFRS 9). - **Limite** : hypothèse de linéarité du log-odds ; sensible aux valeurs extrêmes dans `person_income`.

6 Conclusion et pistes d'amélioration

Nous avons conduit une analyse complète de classification supervisée sur le jeu de données *Credit Risk Dataset*, de l'exploration des données jusqu'à la comparaison de deux classifieurs. Le **feature engineering** (création de `risk_score` et `high_risk_grade`) a enrichi l'espace des variables en s'appuyant sur la connaissance métier révélée par l'analyse exploratoire. Les résultats montrent que la prédiction du défaut de paiement est accessible avec des méthodes classiques, et que certaines variables - notamment `loan_grade`, `loan_int_rate` et `loan_percent_income` - sont particulièrement discriminantes.

Limites rencontrées :

- Le **déséquilibre de classes** (~78 % / 22 %) peut biaiser les classifieurs vers la classe majoritaire. Nous l'avons partiellement compensé en utilisant l'AUC-ROC comme critère d'évaluation plutôt que l'accuracy.
- Les **valeurs aberrantes** dans `person_income` (revenus > 1 M USD) n'ont pas été filtrées ; elles peuvent influencer la régression logistique dont les coefficients dépendent de l'échelle des variables.
- Le classifieur Naïve Bayes suppose l'**indépendance conditionnelle** des variables explicatives, hypothèse mise en défaut par les corrélations observées (notamment entre `loan_int_rate` et `loan_percent_income`), ce qui peut dégrader ses probabilités a posteriori.
- La régression logistique suppose une **relation linéaire** entre les variables explicatives et le log-odds, hypothèse qui peut être mise en défaut par des relations fortement non linéaires.

Pistes non explorées faute de temps :

- **Rééchantillonnage SMOTE** (*Synthetic Minority Over-sampling Technique*) pour rééquilibrer les classes et améliorer le recall sur les défauts.
- **Forêt aléatoire** ou **gradient boosting** (XGBoost) pour de meilleures performances prédictives tout en conservant des mesures d'importance des variables.
- **Optimisation du seuil de décision** : plutôt que d'utiliser le seuil par défaut de 0,5, choisir un seuil qui maximise le recall tout en maintenant une précision acceptable, selon le coût métier des faux négatifs.

7 Déclaration d'utilisation de l'IA

Dans le cadre de ce projet, nous avons eu recours à des outils d'intelligence artificielle pour les tâches suivantes :

- **Support syntaxique et débogage** : L'outil a été utilisé ponctuellement pour nous aider à corriger la syntaxe de certains blocs de code R ou pour ajuster la mise en forme du document `.Rmd` (ajustement des graphiques, esthétique des tableaux avec `kableExtra`). Le code analytique a été conçu par nos soins.
- **Correction et relecture** : Les explications théoriques (sections "Principe et justification") et les interprétations des résultats ont été intégralement rédigées par les membres du groupe à l'aide des supports de cours. L'IA a servi occasionnellement d'outil de correction grammaticale ou d'amélioration typographique.
- Aucune IA n'a été utilisée pour la conception de la démarche analytique, le choix des modèles, le feature engineering, ni pour interpréter les résultats. Toutes les décisions, analyses et conclusions présentées dans ce rapport découlent uniquement de la réflexion et du travail des auteurs.

8 Contributions de chacun

Mohamed FOFANA : recherche et sélection du jeu de données ; rédaction de la section d'introduction et de présentation générale ; implémentation du prétraitement des données et du feature engineering ; implémentation et optimisation du classifieur Naïve Bayes ; rédaction de la comparaison et du choix final ; mise en forme globale du rapport.

Abdou FALL : analyse univariée (statistiques descriptives et graphiques) ; analyse multivariée (matrice de corrélation, boxplots et barplots par cible) ; implémentation et évaluation du classifieur par Régression Logistique ; rédaction de la conclusion et des pistes d'amélioration ; préparation de la présentation orale.

9 Bibliographie

Étiévant, L. (2025-2026). *Compléments de Mathématiques 2 - Introduction au Machine Learning*. Cours L3 MIASHS, Université Grenoble Alpes.

Kaggle. *Credit Risk Dataset* (laotse). https://www.kaggle.com/datasets/laotse/credit-risk-dataset

Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (1984). *Classification and Regression Trees*. CRC Press.

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.

Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. *Journal of Statistical Software*, 28(5), 1–26. https://doi.org/10.18637/jss.v028.i05

Robin, X., Turck, N., Hainard, A., et al. (2011). pROC: an open-source package for R and S+ to analyze and compare ROC curves. *BMC Bioinformatics*, 12, 77. https://doi.org/10.1186/1471-2105-12-77