UNIVERSITÉ GRENOBLE ALPES

L3 MIASHS • Compléments Mathématiques 2

Prédiction du Risque de Défaut de Crédit

Projet de Classification Supervisée

Mohamed FOFANA & Abdou FALL

20 avril 2026

Plan de la présentation

1. Contexte, problématique et présentation des données
2. Exploration des données (EDA)
3. Prétraitement et Feature Engineering
4. Classifieurs (Naïve Bayes & Régression Logistique)
5. Comparaison et choix final
6. Dashboard et déploiement (Docker sur render.com)
7. Limites
8. Conclusion

1. Contexte et Problématique

L'enjeu du Risque Crédit

- Les banques doivent évaluer la *probabilité de défaut* (PD) d'un emprunteur.
- Arbitrage crucial : minimiser les pertes vs maximiser les revenus.

Notre Problématique

Comment construire un modèle d'apprentissage supervisé capable d'identifier les profils à risque à partir de l'historique de crédit, tout en restant interprétable (Normes Bâle III) ?

1. Présentation des Données

32 581	12	21,8%
Observations	Variables	Taux de défaut

Profil Client	Âge, revenu annuel, durée d'emploi, historique
Attributs Prêt	Montant, taux d'intérêt (`loan_int_rate`), grade (A à G)
Variable Cible	`loan_status` (0 = Remboursé, 1 = Défaut)

Données manquantes identifiées :
Taux d'intérêt (9,6% de NA) et Durée d'emploi (2,7% de NA).

2. EDA — Déséquilibre et taux d'intérêt

Déséquilibre de la cible (`loan_status`)

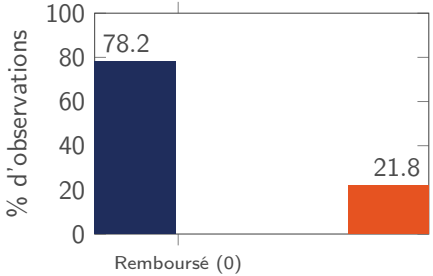

⇒ *Jeu déséquilibré : métriques robustes (AUC, Recall, F1-score).*

Boxplot : taux d'intérêt selon le statut

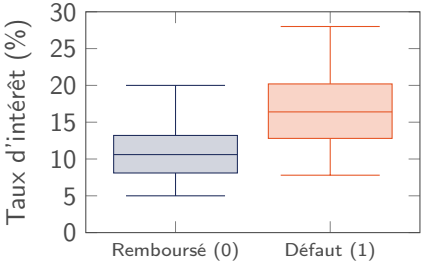

⇒ *Les défauts sont associés à des taux plus élevés.*

2. EDA — Taux de défaut par `loan_grade`

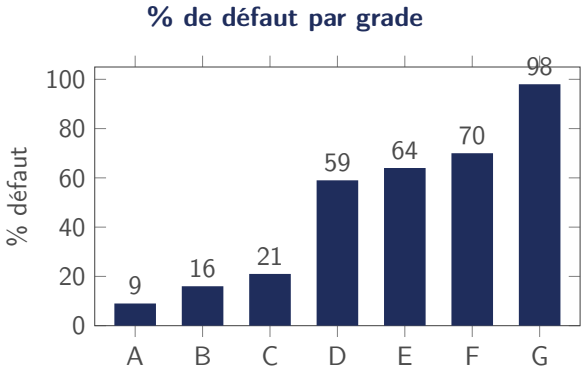

Lecture métier

- Progression quasi-monotone du risque de A vers G.
- Rupture nette à partir des grades D/E.
- Variable `loan_grade` très prédictive.

3. Prétraitement et Feature Engineering

Nettoyage et Imputation

- **Outliers** : Âge > 100 exclus.
- **Split** : Train (80%) / Test (20%) réalisé *avant* l'imputation pour bloquer toute fuite de données (leakage).
- **Valeurs manquantes** : Imputées via la médiane du jeu d'entraînement.

Feature Engineering

Création de variables expertes pour isoler mécaniquement le profil de risque :

- `high_risk_grade` : Indicateur valant 1 si (Grade $\in \{D, E, F, G\}$).
- `risk_score` : Croisement multiplicatif entre le % de revenu engagé et le Taux d'intérêt.

4. Classifieurs : Naïve Bayes

Théorie

Naïve Bayes suppose l'indépendance conditionnelle des variables et applique :
$P(y \mid x_1, \ldots, x_p) \propto P(y) \prod_{j=1}^{p} P(x_j \mid y)$.

Implémentation

- Données prétraitées + `risk_score`, `high_risk_grade`.
- Entraînement sur 80% des données.
- Évaluation sur 20% (jeu test séparé).

Résultats (test)

Métrique	Valeur
AUC-ROC	0,845
Recall défaut	**0,668**
Précision défaut	0,622
Accuracy	0,839

Limite : corrélations entre variables, hypothèse d'indépendance imparfaite.

Grenoble Alpes

4. Classifieurs : Régression Logistique

Théorie

La régression logistique modélise : $\log\left(\frac{p(x)}{1-p(x)}\right) = \beta_0 + \sum_{j=1}^{p} \beta_j x_j$, avec $p(x) = P(\text{défaut} = 1 \mid x)$.

Implémentation

- Standardisation des variables numériques.
- Modèle entraîné sur 80% des données.
- Seuil de décision initial fixé à 0,5.

Résultats (test)

Métrique	Valeur
AUC-ROC	**0,876**
Recall défaut	0,581
Précision défaut	**0,786**
Accuracy	**0,874**

Bilan : forte baisse des faux positifs ($\approx -60\%$) par rapport à Naïve Bayes.

Université Grenoble Alpes

5. Comparaisons et choix final

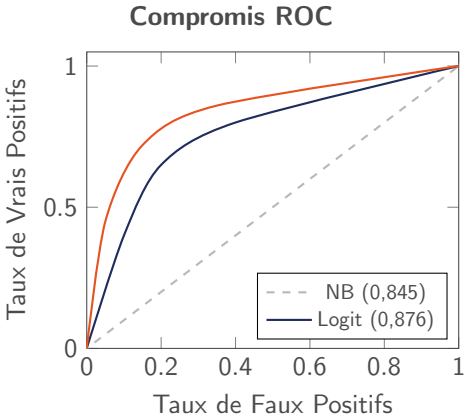

Régression Logistique Vainqueur

- **Performance Pure** : AUC (0,876) et Précision (79%) dominent.
- **Robuste** : Ne souffre pas de la colinéarité des paramètres d'entrée.
- **Expliquabilité** : L'output est une vraie "probabilité calibrée". Ses β_i sont transparents vis-à-vis des auditeurs réglementaires bancaires (Bâle III).

6. Dashboard et Déploiement logiciel

L'algorithme logistique `modele.rds` a été intégré à une interface pour être manipulé par le métier.

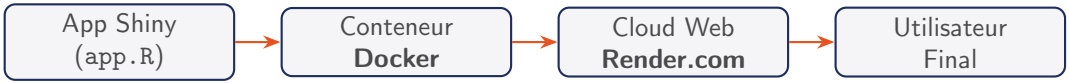

L'application Shiny

- Saisie du profil au guichet.
- Affichage visuel du Risque Crédit issu du modèle ML.
- Déclencheur du Refus ou Acceptation calculé dynamiquement.

Le déploiement Dockerisé

Le code R, le modèle entraîné et l'OS sont packagés dans un **Dockerfile**, puis portés sur **Render.com**, garantissant zéro erreur d'environnement !

UGA
Université
Grenoble Alpes

7. Limites et Axes d'Amélioration

Limites Conceptuelles du Logit

- Le logarithme du ratio des chances n'est potentiellement pas parfaitement linéaire sur le spectre des très hauts revenus.
- Le *Rappel* global de $\sim 58\%$ confirme qu'un grand groupe de candidats faisant défaut est mal étiqueté.

L'Ecueil de la Décision à $p = 0,5$

- Le **déséquilibre de classes initial** (80% vs 20%) bride les performances. Un *SMOTE* n'a pas été ici exploité.
- Parer à $p = 0.5$ ignore le *ratio des coûts assymétriques* en finance (l'argent perdu vaut-il plus que le taux d'intérêt de M. X ?).

8. Conclusion

Réflexion Globale & Apports

- **Prétraitement & Méthodologie** : Isolement des données de test avant imputation des NA, évitant drastiquement les biais statistiques.
- **Choix Mathématique vs Métier** : Mettre à l'écart des approches complexes trop "boîte noire" (RandomForest) ou inadaptées structurellement (Naïve Bayes et son hypothèse aveugle) au bénéfice du classique, mais invincible, logit.
- **Vision Intégrale (Full-Stack Data Data/ML)** : Livrabilité garantie via l'élaboration d'une instance technique Docker déployée par nos soins en direct.

Bilan : Une orchestration end-to-end menant la réflexion depuis la base de données brutes jusqu'à l'interaction par une UI distante accessible au monde entier.

Université Grenoble Alpes

Merci de votre attention

Questions & Démo ?

Mohamed FOFANA & Abdou FALL

Projet Compléments de Mathématiques 2 • L3 MIASHS • UGA